

SPOT.ph Eat + Drink 抓取脚本使用说明

概述

自动抓取 SPOT.ph 网站 Eat + Drink 频道的所有文章，包括标题、日期、作者、正文、图片链接等。

注意：当前没有写截图功能，截图功能要自己写

脚本采用 IndexedDB 中转方案：边滚动边抓取，每篇文章立即写入浏览器 IndexedDB（磁盘），不在 JS 内存中堆积。全部完成后一次性导出为 JSON 文件下载。

文件位置

```
spotph_scraper_v6.js      # 完整版（带注释）
```

使用步骤

1. 打开目标页面

在 Chrome/edge 浏览器中访问：


```
Eat + Drink (https://www.spot.ph/eatdrink?ref=home_wgt2-sections1-eat-  
drink_title)  
Things To Do (https://www.spot.ph/things-to-do?ref=home_wgt2-sections2-things-  
to-do_title)  
Shopping + Services (https://www.spot.ph/shopping?ref=home_wgt2-sections3-  
shopping-services_title)  
News + Explainer (https://www.spot.ph/newsfeatures?ref=home_wgt2-sections4-  
newsfeatures_title)  
Latest: Arts + Culture (https://www.spot.ph/arts-culture?ref=home_wgt2-  
sections5-arts-culture_title)  
Entertainment (https://www.spot.ph/entertainment?ref=home_wgt2-sections6-  
entertainment_title)
```

先手动通过人机验证，然后使用开发者工具（见下面），六个频道**可以同时打开**六个网页并过验证（我写了内存释放逻辑）

等待页面加载完成，确认能看到文章列表。

2. 打开开发者工具

按 **F12** 或 **Ctrl + Shift + J** 打开 Chrome DevTools，切换到 **Console（控制台）** 标签。首次执行要打开权限（不会的截图问AI怎么打开）



3. 粘贴执行脚本

复制下面的完整脚本，在控制台中粘贴并按 `Enter` 执行：

如果控制台没有执行权限的话先按照说明

```

(async function(){const d=m=>new Promise(r=>setTimeout(r,m));function oDB()
{return new Promise((res,rej)=>{let
r=indexedDB.open('SpotPH',1);r.onupgradeneeded=e=>{let
db=e.target.result;if(!db.objectStoreNames.contains('a'))db.createObjectStore('
a',
{keyPath:'index'}}};r.onsuccess=e=>res(e.target.result);r.onerror=e=>rej(e.targ
et.error)}}function dbP(db,a){return new Promise((res,rej)=>{let
t=db.transaction('a','readwrite');t.objectStore('a').put(a);t.oncomplete=res;t.
onerror=e=>rej(e.target.error)}}function dbG(db){return new
Promise((res,rej)=>{let
t=db.transaction('a','readonly'),r=t.objectStore('a').getAll();r.onsuccess=e=>r
es(e.target.result);r.onerror=e=>rej(e.target.error)}}function dbc(db){return
new Promise((res,rej)=>{let
t=db.transaction('a','readwrite');t.objectStore('a').clear();t.oncomplete=res;t
.onerror=e=>rej(e.target.error)}}}let db=await oDB();await
dbc(db);console.log('[DB 就绪]');let seen=new Set(),ok=0,fail=0,idx=0;async
function F(u,i){if(seen.has(u))return null;seen.add(u);try{let r=await
fetch(u),h=await r.text(),p=new
DOMParser(),doc=p.parseFromString(h,'text/html');let
t=doc.querySelector('h1')?.innerText?.trim()||'';let dt='',m=h.match(/Published
on ([A-Z][a-z]+ \d+, \d{4})/);if(m)dt=m[1];let au=doc.querySelector('.author,
[class*=author]')?.innerText?.trim()||'';let I=
[];doc.querySelectorAll('img').forEach(im=>{let
s=im.src||'';if(s&&s.includes('spot.ph')&&!s.includes('logo')&&!s.includes('ico
n')&&!s.includes('ad-')){if(!I.includes(s))I.push(s)}});let C=
[];doc.querySelectorAll('p').forEach(px=>{let
x=px.innerText.trim();if(x.length>20&&!x.includes('cookie')&&!x.includes('Subsc
ribe'))C.push(x)});let a=
{index:i,title:t,url:u,date:dt,author:au,scraped_at:new
Date().toISOString(),images:I,imageCount:I.length,content:C.join('\n\n'),paragr
aphs:C.length};await dbP(db,a);h=doc;r=null;ok++;return a}catch(e){fail++;let
f={index:i,url:u,scraped_at:new Date().toISOString(),error:e.message};await
dbP(db,f);return f}}function ext(){let N=
[];document.querySelectorAll('.article-card').forEach(e=>{let
a=e.querySelector('a'),t=e.querySelector('h2,h3,h4');if(a&&t){let
u=a.href,x=t.innerText.trim();if(u&&x&&!seen.has(u))N.push({title:x,url:u})}});
return N}console.log('=== IndexedDB 中转模式 ===');let pc=0,sr=0;while(sr<5){let
n1=ext();for(let it of n1){idx++;console.log('['+idx+'
'+it.title.substring(0,45));let r=await
F(it.url,idx);if(r&&!r.error)console.log('    ✓ '+r.paragraphs+'p
'+r.imageCount+'img');await
d(600)}window.scrollTo(0,document.body.scrollHeight);await d(2000);let
cc=document.querySelectorAll('.article-
card').length;if(cc===pc)sr++;else{sr=0;pc=cc;console.log('[滚动] '+cc+'
篇')}}let rem=ext();for(let it of rem){idx++;await F(it.url,idx);await
d(600)}console.log('[导出...]');let all=await dbG(db);all.sort((a,b)=>a.index-
b.index);let out={source:'spot.ph/eatdrink',scraped_at:new
Date().toISOString(),total:all.length,success:ok,failed:fail,articles:all};let
b=new Blob([JSON.stringify(out,null,2)],
{type:'application/json'}),u=URL.createObjectURL(b),e1=document.createElement('
a');e1.href=u;e1.download='spotph_'+new
Date().toISOString().slice(0,10)+'.json';document.body.appendChild(e1);e1.click
();document.body.removeChild(e1);URL.revokeObjectURL(u);await
dbc(db);db.close();console.log('完成! '+ok+'/'+(ok+fail)+' 已下载'))}()

```

4. 等待执行完成

脚本运行期间，控制台会显示进度：

```
=== IndexedDB 中转模式 ===
[1] LOOK: A Café Just Opened Inside National Muse...
    ✓ 8p 5img
[2] Spiral's Chef Returns With Curio in QC, Eleva...
    ✓ 6p 3img
...

[滚动] 25 篇
[滚动] 30 篇
...

[导出...] ← 全部完成，自动下载 JSON 文件
完成！ 21/21 已下载
```

5. 获取结果

下载的 JSON 文件保存在浏览器默认下载目录：

下载完后会弹出让你命名的方框的，自行根据频道名称处理：

```
Windows: C:\Users\<用户名>\Downloads\spotph_2026-05-20.json
```

输出文件格式

```
{
  "source": "spot.ph/eatdrink",
  "scraped_at": "2026-05-20T10:30:45.123Z",
  "total": 21,
  "success": 21,
  "failed": 0,
  "articles": [
    {
      "index": 1,
      "title": "LOOK: A Café Just Opened Inside National Museum of Fine Arts",
      "url": "https://www.spot.ph/eatdrink/the-latest-eat-drink/...",
      "date": "May 19, 2026",
      "author": "Jerome Gomez",
      "scraped_at": "2026-05-20T10:31:02.456Z",
      "images": ["https://images.spot.ph/..."],
      "imageCount": 5,
      "content": "完整正文段落，用换行符分隔...",
      "paragraphs": 8
    }
  ]
}
```

字段说明

字段	类型	说明
index	number	文章序号
title	string	文章标题
url	string	文章链接
date	string	发布日期
author	string	作者
scraped_at	string	采集时间 (ISO 8601)
images	array	图片 URL 列表
imageCount	number	图片数量
content	string	正文全文 (段落用 \n\n 分隔)
paragraphs	number	段落数量
error	string	仅失败时出现, 错误信息

工作原理

浏览器页面

1. 自动向下滚动 → 触发懒加载更多文章

2. 提取新出现的文章链接

3. 逐篇 `fetch` 获取 `HTML` → 解析 → 提取字段

4. 每篇立即写入 `IndexedDB` (磁盘) → 释放内存

5. 重复直到没有新文章加载

6. 全部完成后从 `IndexedDB` 导出 → 排序 → 下载 `JSON`

7. 清理 `IndexedDB`

内存占用

阶段	JS 内存占用
抓取中	极低 (始终只有 1 篇在内存)
导出时	约等于文件大小 (21 篇 ≈ 200KB, 10000 篇 ≈ 50MB)
完成后	归零 (<code>IndexedDB</code> 已清理)

预估时间与大小

文章数	预估耗时	文件大小
21 篇	~30 秒	~200 KB
100 篇	~2 分钟	~1 MB
500 篇	~10 分钟	~5 MB
1000 篇	~20 分钟	~10 MB
10000 篇	~3 小时	~50-80 MB

注意事项

1. 当前没有截图功能，截图功能要自己写
2. 网络要求：需要能正常访问 spot.ph
3. 浏览器要求：Chrome / Edge（需要支持 IndexedDB）
4. 不要关闭页面：脚本运行期间不要关闭或刷新页面
5. 反爬风险：每篇间隔 600ms，大量抓取时可能触发网站限流
6. 断点续抓：当前版本不支持中断恢复，如需可手动改造

故障排除

Q: 控制台报错 `Unexpected end of input`

A: 脚本没有完整粘贴，请确保从 `(async` 到最后的 `})();` 全部复制。

Q: 抓取过程中页面卡住

A: 正常现象，脚本在等待滚动加载。如需中止，刷新页面即可。

Q: 下载的 JSON 文件为空

A: 可能是页面未完全加载就执行了脚本，刷新页面后重试。

Q: 大量文章抓取被网站拦截

A: 增大脚本中的 `delay(600)` 值，改为 `delay(2000)` 或更大。